

Singular Learning Theory 1

中野志颯

[2026-03-18 Wed]

Contents

1	1 章 イントロ	2
1.1	ベイズ推測の定義	2
1.1.1	統計的推測の問題設定→機械学習との関連は？	2
1.1.2	サンプルの現れ方に対する平均値	3
1.1.3	ベイズ推測の道具立て：	3
1.1.4	事後分布による期待値・平均と予測分布	3
1.1.5	ベイズ推測についての著者のまとめ	3
1.2	考察される量について	3
1.2.1	分配関数と自由エネルギー	4
1.2.2	推測と汎化	4
1.2.3	事後分布が計算可能な例	4
1.3	さまざまな統計的推測	4
1.4	事後分布の例 (python)	4
1.4.1	ケース (i): $(a_0, b_0) = (0.5, 3.0)$	5
1.4.2	ケース (ii): $(a_0, b_0) = (0.5, 1.0)$	5
1.4.3	ケース (iii): $(a_0, b_0) = (0.5, 0.5)$	5
1.5	確率モデルの例 (久保川)	7
1.6	この本の流れ	7
1.7	一般的注意??	7
1.8	質問と回答	7
1.9	演習問題	7
2	2 章 基礎概念	8
3	3 章 正則理論	8
4	4 章 一般理論	8

5	5 章 事後分布の実現	8
6	6 章 ベイズ統計学の諸問題	8
7	7 章 ベイズ統計の基礎	8
8	8 章 初等確率論の基礎	8
8.1	確率分布と確率変数	8
8.2	平均と分散	8
8.3	同時分布と条件付き確率	8
8.4	カルバック・ライブラ情報量	8
8.5	極限定理	8
8.5.1	確率変数の収束	8
8.5.2	対数の法則と中心極限定理	8
8.5.3	経験課程	8
9	雑多なメモ	8
9.1	W bayes cp2	9
9.1.1	概要	9
10	代数幾何と学習理論からの抜粋	9
10.1	統計的推測の問題設定	10
10.2	ベイズ法	10
11	めも	10

1 1 章 イントロ

ここでは、ベイズ推測を定義する。

1.1 ベイズ推測の定義

1.1.1 統計的推測の問題設定→機械学習との関連は？

N と n を自然数とする. N 次元実ユークリッド空間 $\mathbb{R}^N$ 上に n 個の点の集合

$$x_1, x_2, \dots, x_n$$

がある場合を考える. 言い換えると

$$x_i \in \mathbb{R}^N, \quad (i = 1, 2, \dots, n)$$

である.

サンプルをまとめて x^n と書く．つまり

$$x^n = (x_1, x_2, \dots, x_n) \in \mathbb{R}^N \times \mathbb{R}^N \times \dots \times \mathbb{R}^N = (\mathbb{R}^N)^n$$

ここでサンプルを，確率変数の実現値であることを考える．この時のサンプル x^n の確率密度関数は

で，サンプル x_n は上記の確率密度関数で定まる分布に従う確率変数 $\mathbf{X}^N$ の実現値と考える． $q(x)$ を真の分布という．

現実には真の分布は不明であって，サンプルだけが与えられることが多い．統計的推測もしくは統計的学習では，与えられた有限 n 個のサンプルから真の分布を推測することを考える．統計的推測の手続きによって得られる結果は，確率的に変動するサンプルによるものであるから，これもまた確率的である．この結果の確率的な挙動を調べる必要がある．（なんで？）

1.1.2 サンプルの現れ方に対する平均値

サンプルを

1.1.3 バイズ推測の道具立て：

1. 確率モデル
2. 事前分布
3. 逆温度 β の事後分布
4. 分配関数と周辺尤度

1.1.4 事後分布による期待値・平均と予測分布

1.1.5 バイズ推測についての著者のまとめ

1.2 考察される量について

- バイズ推測のフレームワーク
 - サンプル X^N ，確率モデル，事前分布 $\rightarrow$ 予測分布 $p^*(x) = p(x|X^N)$ を構成する
 - 統計的推測（のプロセスとその結果）は確率的な現象
- 自由エネルギーと汎化誤差が重要な量である

1.2.1 分配関数と自由エネルギー

1.2.2 推測と汎化

1.2.3 事後分布が計算可能な例

1. 指数型分布
2. INBOX 久保川で例題

1.3 さまざまな統計的推測

1.4 事後分布の例 (python)

例 2 $x \in \mathbb{R}^1$ とし, 関数 $\mathcal{N}(x)$ を平均 0 で分散が 1 の正規分布とする。すなわち

$$\mathcal{N}(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \quad (1.26)$$

とする。

パラメータ $w = (a, b)$ ($0 \leq a \leq 1, b \in \mathbb{R}^1$) をもつ確率モデル

$$p(x|w) = (1-a)\mathcal{N}(x) + a\mathcal{N}(x-b) \quad (1.27)$$

を考える。(2 個の正規分布の混合)

以下では, パラメータの集合が

$$W = \{(a, b) ; 0 \leq a \leq 1, |b| \leq 5\} \quad (1.28)$$

である場合を考える。また, 簡単のために事前分布は場所によらず一定値をとる場合を考える。すなわち

$$\varphi(w) = \frac{1}{10} \quad (1.29)$$

とする。この場合, 事後分布は尤度関数と同じ形状をしている。また, この例では事後分布 $p(w|X^n)$ を最大にする w が最尤推定量であり, 事後確率最大化推定量と同じである。真の分布を $q(x) = p(x|a_0, b_0)$ として

$$(a_0, b_0) = (0.5, 3.0), (0.5, 1.0), (0.5, 0.5) \quad (1.30)$$

の 3 通りのケースを比較してみよう。 (a_0, b_0) を真のパラメータと呼ぶことにする。サンプルの個数は $n = 100$ の場合を考える。




Figure 1: 混合正規分布モデル $p(x|w)$ の事後分布の例 ($n = 100$)

1.4.1 ケース (i): $(a_0, b_0) = (0.5, 3.0)$

二つの確率分布 $\mathcal{N}(x)$ と $\mathcal{N}(x - 3.0)$ は、区別できる程度に離れているので、100 個のデータがあれば真の分布が二つの正規分布の混合であることは明確にわかんと思われる。実際、事後分布を図 1.1 に示す。事後分布は真のパラメータの付近に鋭いピークをもつ分布であり正規分布で近似できそうである。最尤推定量は $(0.47, 3.05)$ であり、真のパラメータ $(0.5, 3.0)$ の近くにある。この場合には事後分布の形状はサンプルの出方にあまり依存しない。事後分布の位置はサンプルの出方によってばらつくが、そのばらつきは小さい。

1.4.2 ケース (ii): $(a_0, b_0) = (0.5, 1.0)$

二つの確率分布 $\mathcal{N}(x)$ と $\mathcal{N}(x - 1.0)$ は、重なっている部分が大きく、データが 100 個あっても、真の分布が二つの正規分布の重なりであるのか、一つの正規分布なのかは見分けがつかないかもしれない。実際、事後分布を図 1.2 に示す。事後分布は真のパラメータの付近からずれて広がっていて正規分布では近似できなさそうである。最尤推定量は $(0.65, 0.55)$ であり、真のパラメータ $(0.5, 1.0)$ からずれている。この場合には同じサンプル数であっても、サンプルの出方により事後分布の位置や形状は変化する。最尤推定量の位置も変化する。

1.4.3 ケース (iii): $(a_0, b_0) = (0.5, 0.5)$

二つの確率分布 $\mathcal{N}(x)$ と $\mathcal{N}(x - 0.5)$ は、ほとんど重なっているなので、データが 100 個くらいでは、真の分布は一つの確率分布であるように見えるだろう。実際、事後分布を図 1.3 に示す。事後分布は真のパラメータの近くではなく、 $ab \approx 0$ を満たす集合全体のまわりに広がっていて正規分布では近似できない。最尤推定量は $(0.15, 0.71)$ であり、真のパラメータ $(0.5, 0.5)$ とは異なる位置にある。この場合には、事後分布の位置や形状はサンプルの出方により大きく変わる。図 1.3 で示したのは一例にすぎず、サンプルの出方が異

なれば、事後分布の形はまったく違ったものになる。最尤推定量もその位置は確率的に大きく変動する。




Figure 2: 3通りの真のパラメータに対する事後分布 ($n = 100$)

注意 10 上記の例はサンプル数が百個の場合のものである。真のパラメータが $(0.5, 0.5)$ の場合にはサンプル数が千個でも、二つの正規分布の区別は付きにくい、サンプル数が百万個程度あれば、ほぼ区別が付いて事後分布は図 1.1 と同じように真のパラメータの周りに鋭いピークをもつようになる。すなわち事後分布はサンプル数の変化とともにその形を大きく変える。

従来の統計学の理論では、事後分布あるいは尤度関数が図 1.1 のように局所的に鋭いピークをもち正規分布で近似できる場合を想定することが多かった。しかしながら、現実問題では、事後分布が図 1.2, 図 1.3 のように大域的な広がりをもつケースがしばしば生じている。また、図 1.1 のように正規分布で近似できる場合を考えると、ベイズ推測も最尤推測も他の推測もほぼ同じ推測精度であるが、図 1.2, 図 1.3 のように事後分布が正規分布で近似できない場合には、ベイズ推測が他の方法よりも優れた推測精度をもっていることがわかる。本書では、3 章において事後分布が正規分布で近似できる場合の理論を述べ、4 章で事後分布が大域的な広がりをもつ場合でも扱うことができる理論をつくる。

- 1.5 確率モデルの例（久保川）
 - 1.6 この本の流れ
 - 1.7 一般的注意??
 - 1.8 質問と回答
 - 1.9 演習問題
-

- 2 2章 基礎概念
 - 3 3章 正則理論
 - 4 4章 一般理論
 - 5 5章 事後分布の実現
 - 6 6章 ベイズ統計学の諸問題
 - 7 7章 ベイズ統計の基礎
 - 8 8章 初等確率論の基礎
 - 8.1 確率分布と確率変数
 - 8.2 平均と分散
 - 8.3 同時分布と条件付き確率
 - 8.4 カルバック・ライブラ情報量
 - 8.5 極限定理
 - 8.5.1 確率変数の収束
 - 8.5.2 対数の法則と中心極限定理
 - 8.5.3 経験課程
-

9 雑多なメモ

$$\mathbf{W} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

逆温度 β の, パラメータの事後分布は,

$$p(w|X^n) = \frac{1}{Z_n(\beta)} \phi(w) \prod_{i=1}^N p(X_i|w)^\beta$$

$$p(w | X^n) = \frac{1}{Z_n(\beta)} \phi(w) \prod_{i=1}^N p(X_i | w)^\beta$$

ここで $Z_n(\beta)$ は分配関数

$$Z_n(\beta) = \int \phi(w) \prod_{i=1}^N p(X_i | w)^\beta dw$$

$Z_n(1)$ は周辺尤度

分配関数（正規化定数）

$Z_n(\beta) = \int_W \phi(w) \prod_{i=1}^N p(X_i | w)^\beta dw$ 予測分布は、確率モデルを事後分布によって平均化したものである（？ → 後で確かめてみるか）

9.1 W bayes cp2

9.1.1 概要

- 真の分布と確率モデルの実現可能性
 - 具体例付き
- 平均対数損失関数の定義
- 最適なパラメータの集合の定義
 - 補題 2
 - * 2-1: 最適なパラメータ集合の要素は 1 つとは限らない
 - * 2-2: 最適なパラメータ集合ないのパラメータによって決まる確率モデルはすべて同じとは限らない
- 実質的にユニーク（定義）

$p(x | w)$ に対して、真のパラメータ集合 W_0

10 代数幾何と学習理論からの抜粋

サンプルから真の構造を推測する学習モデルにおいては、真の構造はパラメータ空間の中の特異点を持つ解析的集合になっている。

（意味がわからん。真の構造とは、真の分布の構造のことなのか？）ここでは、その場合に必要となる学習理論の基本定理を紹介する。

10.1 統計的推測の問題設定

ユークリッド空間 $\mathbf{R}^N$ 上の確率密度関数 $q(x)$ があって、確率分布 $q(x)dx$ に従う n 個の独立な確率変数 $\mathbf{X}^N = (X_1, X_2, \dots, X_N)$ があるとする。このとき $\mathbf{X}^N$ をサンプルという。(学習データ、例とか) これの生成源となる確率分布 $q(x)dx$ を真の分布とか情報源という。

学習理論(統計的推測)でやりたいことは、「サンプル $\mathbf{X}^N$ から真の分布 $q(x)$ を推測する」である。

ユークリッド空間上の確率密度関数 $q(x)$ (ってなに?) には無限の可能性があるので、一切の仮定をおかずに、有限個のサンプルを見ているだけでは推測はできない。現実的に推測を可能にするためには何らかの仮定を置く必要がある。ここで置く仮定によって以下で説明するベイズ学習(ベイズ推論)が可能になる。

なので、ベイズ法とは、高次の意味での学習すなわち真の分布の推測を達成するための一連の仮定の置き方に関するルールと、それらの仮定によって可能になる方法論のあつまり(フレームワーク)と捉えられる?

10.2 ベイズ法

データ分析者は、パラメータ $w \in \mathbf{W}^d$ によって定まる $x \in \mathbf{R}^N$ の条件付き確率密度分布 $p(x|w)$ と、パラメータ $w \in \mathbf{W}^d$ の確率密度分布 $\phi(w)$ を定める。 $p(x|w)$ を統計モデルや確率モデル、 $\phi(w)$ を事前分布という。

次に、事後分布を以下で定義する。

11 めも

latex が複雑になってしまう場合は github で管理すれば良い→リンクを後でここに貼る

```
M-: (setq org-format-latex-options (plist-put org-format-latex-options :scale 0.5))
```

そうです。カーソル位置の数式 1 つだけです。

****スコープまとめ****

```
| キー | 範囲 |
|-----|-----|
| `C-c C-x C-1` | カーソル位置の数式 1 つ |
```

| `C-u C-c C-x C-1` | **セクション内**の全数式 |
| `C-u C-u C-c C-x C-1` | **バッファ全体**の全数式 |

スケールを変えた後は `C-u C-u C-c C-x C-1` でバッファ全体に一括適用するのが楽です。